

使用说明: 本资料是考试用的详细参考手册。按章节/主题组织, 包含所有公式推导、计算步骤、典型例题。遇到题目先从目录定位章节, 再查对应公式和例题。

目录

- A. 图像滤波与卷积
- B. 边缘检测
- C. 图像重采样与插值
- D. Harris 角点检测
- E. 特征不变性与 SIFT
- F. 特征描述子与匹配
- G. 图像变换与单应
- H. 图像对齐与最小二乘
- I. RANSAC
- J. 相机与投影
- K. 立体视觉
- L. 神经网络基础
- M. CNN/RNN/Attention/Transformer
- N. 最大似然估计与 KL 散度
- O. 潜变量模型与 VAE
- P. 标准化流模型
- Q. GAN
- R. f-散度与 f-GAN 与 WGAN
- S. BiGAN 与 CycleGAN
- T. 能量模型 EBM
- U. 分数匹配与 NCE
- V. 扩散模型
- W. Practice Session 例题精解

A. 图像滤波与卷积

A.1 卷积 (Convolution)

定义: 用卷积核 H 对图像 F 进行加权求和

G[i, j] = \sum_m \sum_n H[m, n] \cdot F[i - m, j - n]

关键性质: - 交换律: f * g = g * f - 结合律: (f * g) * h = f * (g * h) -> 可先合并核再卷积 - 分配律: f * (g + h) = f * g + f * h - 可分离: 若核可分解为行 x 列, 则 2D 卷积 -> 两个 1D 卷积, 复杂度从 O(k^2) 降到 O(2k)

卷积 vs 互相关 (Correlation): - 卷积: 核需翻转 180 -> H[m, n] \cdot F[i - m, j - n] - 互相关: 核不翻转 -> H[m, n] \cdot F[i + m, j + n] - 对称核 (如高斯) 二者等价

A.2 高斯滤波器 (Gaussian Filter)

G_{\sigma}(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)

核心性质: - 低通滤波器: 去除高频 (细节/噪声), 保留低频 (整体结构) - 两个高斯卷积仍为高斯: \sigma_{\text{eff}} = \sqrt{\sigma_1^2 + \sigma_2^2} - 可分离: G_{2D}(x, y) = G_{1D}(x) \cdot G_{1D}(y), 大大减少计算量 - 核越大 (\sigma 越大) -> 越模糊

例题: 先用 \sigma_1 = 3 的高斯卷积, 再用 \sigma_2 = 4 的高斯卷积, 等效 \sigma = \sqrt{9 + 16} = \sqrt{25} = 5

A.3 锐化 (Sharpening)

公式: sharpened = original + \alpha \times (\text{original} - \text{blurred})

当 \alpha = 1 时: sharpened = 2 \cdot \text{original} - \text{blurred}

原理: 高通滤波 = 原图 - 低通滤波结果, 突出边缘和细节

A.4 中值滤波 (Median Filter)

- 非线性滤波器, 取窗口内中值
- 特别适合去除椒盐噪声 (salt & pepper noise)
- 保留边缘的同时去噪

B. 边缘检测

B.1 图像梯度 (Image Gradient)

\nabla f = \left[\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right]

- 梯度幅值: \|\nabla f\| = \sqrt{(\partial f / \partial x)^2 + (\partial f / \partial y)^2}
- 梯度方向: \theta = \text{atan2}(\partial f / \partial y, \partial f / \partial x), 垂直于边缘方向

离散近似: - 简单差分: [-1, 1] 或 [[-1], [1]] - Sobel 算子 (更鲁棒, 包含平滑): - x 方向: S_x = [[-1, 0, 1], [-2, 0, 2], [-1, 0, 1]] - y 方向: S_y = [[1, 2, 1], [0, 0, 0], [-1, -2, -1]]

B.2 Canny 边缘检测器 (步骤)

- 高斯平滑: 用 G_{\sigma} 平滑图像, 去噪
- 计算梯度: 求幅值和方向 (用 Sobel 等算子)
- 非极大值抑制 (NMS): 在梯度方向上, 只保留局部极大值像素, 使边缘变细
- 双阈值 + 滞后:
 - 强边缘: R > T_{\text{high}} \rightarrow \text{确定保留}
 - 弱边缘: T_{\text{low}} < R < T_{\text{high}} \rightarrow \text{仅当与强边缘相连时保留}
 - 非边缘: R < T_{\text{low}} \rightarrow \text{丢弃}

B.3 LoG 与 DoG

- Laplacian of Gaussian (LoG): \nabla^2 G = 二阶导数, 在边缘处过零点
- Difference of Gaussians (DoG): DoG \approx \text{LoG}, 用两个不同 \sigma 的高斯之差近似, 计算更高效
- 尺度空间: 边缘位置可能随 \sigma 偏移; 两边缘可合并但不能分裂

C. 图像重采样与插值

C.1 混叠 (Aliasing) 与奈奎斯特

- 奈奎斯特采样定理: 采样率 \geq 2 \times \text{最高频率}, 否则产生混叠
- 解决方案: 下采样前先用高斯低通滤波 (Anti-aliasing)

例题: 图像最高频率 50 \text{ cycles/pixel} \rightarrow \text{最低采样率} = 2 \times 50 = 100 \text{ samples/pixel}

C.2 高斯金字塔 (Gaussian Pyramid)

- 反复: 高斯模糊 \rightarrow 2 倍下采样
- 每层分辨率减半
- 总空间 = 原图 \times (1 + 1/4 + 1/16 + \dots) = \text{原图} \times 4/3

C.3 拉普拉斯金字塔 (Laplacian Pyramid)

- L_i = G_i - \text{Upsample}(G_{i+1}), 存储每层的差异 (细节)
- 可用于图像融合 (Blending): 各层分别融合再重建

C.4 插值方法

方法	效果	速度
最近邻 (Nearest)	方块效应	最快
双线性 (Bilinear)	较好, 帐篷函数	中等
双三次 (Bicubic)	最好	最慢

双线性插值计算: 对四个最近整数点的值, 先在 x 方向插值两次, 再在 y 方向插值一次 (或反过来)。

D. Harris 角点检测

D.1 核心思想

在各方向移动小窗口, 如果图像强度变化都很大 -> 角点

D.2 SSD 误差与二阶矩矩阵

E(u, v) = \sum_{(x, y) \in W} w(x, y) [I(x + u, y + v) - I(x, y)]^2

小运动泰勒展开近似:

E(u, v) \approx \begin{bmatrix} u & v \end{bmatrix} H \begin{bmatrix} u \\ v \end{bmatrix}

二阶矩矩阵 (Second Moment Matrix / Structure Tensor):

H = \sum_{(x, y) \in W} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}

D.3 特征值分类

\lambda_1, \lambda_2	分类	直觉
都 \approx 0	平坦区域 (flat)	各方向无变化
一大一小	边缘 (edge)	仅一个方向变化大
都很大且接近	角点 (corner)	各方向变化都大

D.4 Harris 响应函数

R = \det(H) - \alpha \cdot \text{trace}(H)^2 = \lambda_1 \lambda_2 - \alpha (\lambda_1 + \lambda_2)^2

- \alpha \in [0.04, 0.06]
- R > 0 且为局部极大 -> 角点
- R < 0 -> 边缘
- |R| \approx 0 -> 平坦

例题: H 的特征值 \lambda_1 = 5000, \lambda_2 = 50 - \lambda_1 \gg \lambda_2 \rightarrow \text{一大一小} \rightarrow \text{边缘区域} - 验证: R = 5000 \times 50 - 0.05 \times 5050^2 = 250000 - 1275125 = -1025125 < 0 \checkmark

D.5 Harris 检测完整步骤

- 1. 计算图像梯度 I_x, I_y (Sobel)
- 2. 计算 $I_x^2, I_y^2, I_x \cdot I_y$
- 3. 对上述三项分别做高斯平滑 (得到 H 的各元素)
- 4. 计算每个像素的 R 值
- 5. 非极大值抑制 (NMS)
- 6. 阈值化

D.6 Harris 的不变性

变换	不变?
平移	✓ 等变
旋转	✓ 等变 (特征值不变)
强度缩放 $I \rightarrow aI + b$	✓ 部分不变
尺度变化	✗ 不不变

E. 特征不变性与 SIFT

E.1 不变性 vs 等变性

- 不变性 (Invariance): $f(T(x)) = f(x)$, 输出不变
- 等变性 (Equivariance): $f(T(x)) = T(f(x))$, 输出随变换做对应变化

E.2 尺度不变检测

核心思想: 在位置和尺度两个空间同时找局部极大值

- LoG (Laplacian of Gaussian): $\sigma^2 \cdot \nabla^2 G$ 在特征尺度处产生峰值响应
- DoG (Difference of Gaussians): SIFT 使用, 近似 LoG
- 特征尺度 (Characteristic Scale): 产生 LoG 最大响应的 σ 值

SIFT 关键点检测: 在 DoG 尺度空间中找 3D 极值点 (x, y, σ)

E.3 SIFT 描述子 (128 维)

- 1. 取关键点周围 16×16 窗口
- 2. 按主方向 (dominant orientation) 旋转窗口 $\rightarrow$ 旋转不变
- 3. 分成 $4 \times 4 = 16$ 个小格 (cell)
- 4. 每个小格内统计 8 个方向的梯度直方图
- 5. 128 维 = $4 \times 4 \times 8$ 描述子
- 6. L2 归一化 $\rightarrow$ 光照不变

F. 特征描述子与匹配

F.1 描述子对比

描述子	维度	特点
SIFT	128	尺度 + 旋转不变, 鲁棒但慢
HOG	变长	梯度方向直方图 + 块归一化, 用于行人检测
ORB	256 bits	oFAST+rBRIEF 二进制描述子, 极快

F.2 匹配方法

- L2 距离: $\|f_1 - f_2\|$
- 比值距离 (Ratio Test, Lowe): $d(\text{best})/d(\text{second_best}) < 0.8 \rightarrow$ 接受
- 消除歧义匹配, 非常有效

F.3 评估指标

- ROC 曲线: TPR vs FPR, AUC 越大越好
- Precision/Recall: 精确率和召回率

G. 图像变换与单应

G.1 变换层级 (从简单到复杂)

变换	DOF	矩阵形式	保持性质
平移 (Translation)	2	$[[1, 0, t_x], [0, 1, t_y], [0, 0, 1]]$	方向、长度、平行
欧氏/刚体 (Euclidean)	3	$[[\cos \theta, -\sin \theta, t_x], [\sin \theta, \cos \theta, t_y], [0, 0, 1]]$	角度, 长度, 平行
相似 (Similarity)	4	$[[s \cos \theta, -s \sin \theta, t_x], [s \sin \theta, s \cos \theta, t_y], [0, 0, 1]]$	角度, 长度, 平行, 形状
仿射 (Affine)	6	$[[a, b, t_x], [c, d, t_y], [0, 0, 1]]$	平行线
射影/单应 (Projective)	8	$[[h_1, h_2, h_3], [h_4, h_5, h_6], [h_7, h_8, h_9]]$	直线 (平行不一定)

G.2 单应变换 (Homography)

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \sim \begin{bmatrix} h_1 & h_2 & h_3 \\ h_4 & h_5 & h_6 \\ h_7 & h_8 & h_9 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

- 8 DOF (up to scale, 除以 $h_9 = 1$)
- 最少需要 4 点对应 (每对给 2 个方程)
- 求解: 构造 $Ah = 0$, SVD 取最小奇异值对应的右奇异向量

G.3 前向与逆向变形 (Warping)

- 前向 (Forward): 源像素 $\rightarrow$ 目标位置, 可能有空洞 (holes)
- 逆向 (Inverse): 对每个目标像素, 用 T^{-1} 找源位置, 再插值 $\rightarrow$ 推荐, 无空洞

H. 图像对齐与最小二乘

H.1 最小二乘 (Least Squares)

求解 $Ax = b$ 的最小二乘解:

$$x^* = (A^T A)^{-1} A^T b$$

- 平移: 2 个未知数, ≥ 1 对匹配, 最优解 = 平均位移
- 仿射: 6 个未知数, ≥ 3 对匹配
- 单应: 8 个未知数, ≥ 4 对匹配, 用 SVD 求解 $Ah = 0$

H.2 SVD 求解单应

对每对点 $(x, y) \rightarrow (x', y')$, 构造两行方程:

$$\begin{bmatrix} -x, & -y, & -1, & 0, & 0, & 0, & x'x, & x'y, & x' \end{bmatrix} [h_1 \dots h_9]^T = 0$$
$$\begin{bmatrix} 0, & 0, & 0, & -x, & -y, & -1, & y'x, & y'y, & y' \end{bmatrix} [h_1 \dots h_9]^T = 0$$

4 对点给 8 个方程, SVD 分解 $A, h = V$ 的最后一列 (最小奇异值对应)

I. RANSAC

I.1 算法步骤

- 1. 随机选 s 个点 (s = 模型最小需要的点数)
- 2. 拟合模型 (如单应、基础矩阵等)
- 3. 计算所有点到模型的距离, 统计内点 (距离 $< \epsilon$ 的点)
- 4. 重复 N 次
- 5. 选内点最多的模型
- 6. 用所有内点重新拟合 (最小二乘)

I.2 迭代次数公式

$$N = \frac{\log(1 - p)}{\log(1 - (1 - e)^s)}$$

- p = 期望成功概率 (如 0.99)
- e = 外点比例 (outlier ratio)
- s = 最小样本数

I.3 各模型的最小样本数

模型	s
直线	2
仿射	3
单应	4
基础矩阵	8(或 7)

I.4 计算例题

问题: 单应 ($s = 4$), 外点 30%, $p = 0.99$

$$N = \frac{\log(1 - 0.99)}{\log(1 - (0.7)^4)} = \frac{\log(0.01)}{\log(1 - 0.2401)} = -4.605 / \log(0.7599) = -4.605 / (-0.2744) \approx \mathbf{16.8} \rightarrow \mathbf{17} \text{ 轮}$$

问题: 直线 ($s = 2$), 外点 50%, $p = 0.99$

$$N = \frac{\log(0.01)}{\log(1 - (0.5)^2)} = -4.605 / \log(0.75) = -4.605 / (-0.2877) \approx \mathbf{17} \text{ 轮}$$

J. 相机与投影

J.1 针孔相机模型 (Pinhole Camera)

3D 点 $(X, Y, Z) \rightarrow$ 2D 像素 (u, v) :

$$u = f \cdot \frac{X}{Z} + c_x, \quad v = f \cdot \frac{Y}{Z} + c_y$$

J.2 完整投影矩阵

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} \sim K[R|t] \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

内参矩阵 (Intrinsics):

$$K = \begin{bmatrix} f_x & s & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

- f_x, f_y : 焦距 (像素单位) - (c_x, c_y) : 主点 (通常接近图像中心) - s : skew(通常 = 0)

外参 (Extrinsics): $[R|t] = 3 \times 4$ 矩阵 - R : 3×3 旋转矩阵 (世界 $\rightarrow$ 相机) - t : 3×1 平移向量

J.3 投影类型

类型	公式	特点
透视 (Perspective)	$(fX/Z, fY/Z)$	近大远小、平行线汇聚
正交 (Orthographic)	(X, Y)	无近大远小、忽略深度
弱透视 (Weak Perspective)	(sX, sY)	缩放正交、适合深度变化小的场景

J.4 径向畸变 (Radial Distortion)

$$r_{corrected} = r(1 + k_1r^2 + k_2r^4 + \dots)$$

- 桶形畸变 (Barrel): 图像膨胀, $k_1 < 0$
- 枕形畸变 (Pincushion): 图像收缩, $k_1 > 0$

K. 立体视觉

K.1 视差与深度 (核心公式)

$$Z = \frac{f \cdot B}{d}$$

- Z = 深度
- f = 焦距 (像素)
- B = 基线 (两相机间距)
- d = 视差 = $x_{\text{left}} - x_{\text{right}}$

例题: $f = 500\text{px}$, $B = 0.2\text{m}$, $d = 50\text{px} \rightarrow Z = 500 \times 0.2 / 50 = \mathbf{2.0m}$
例题: $f = 1000\text{px}$, $B = 0.1\text{m}$, $d = 25\text{px} \rightarrow Z = 1000 \times 0.1 / 25 = \mathbf{4.0m}$
注意: 深度与视差成反比, 视差越小 $\rightarrow$ 深度越大 $\rightarrow$ 精度越低

K.2 极线约束 (Epipolar Constraint)

- 左图中的点, 在右图中对应一条极线
- 匹配搜索从 2D 降为 1D $\rightarrow$ 大幅减少计算
- 校正 (Rectification) 后, 极线变为水平线

K.3 立体匹配

SSD 匹配: 在一行上滑动窗口, 计算平方差之和
窗口大小权衡: - 窗口小: 更多细节, 但更多噪声 - 窗口大: 更平滑, 但丢失细节, 边缘模糊

K.4 立体视觉能量最小化

$$E(d) = \sum_x \text{data_cost}(x, d(x)) + \lambda \sum_{x,y \text{ neighbors}} \text{smooth_cost}(d(x), d(y))$$

- data cost: 匹配代价 (SSD, SAD, ZNCC 等)
- smooth cost: 平滑项, 鼓励视差连续
 - Potts 模型: 0 if $d(x) = d(y)$, else λ
 - L1: $|d(x) - d(y)|$

K.5 多视图立体 (MVS)

- SSSD:** 多基线 SSD 之和, 更鲁棒
- 平面扫描 (Plane Sweep): 在不同深度扫描平面, 重投影 + 比较

L. 神经网络基础

L.1 线性分类器

$$f(x, W) = Wx + b$$

三个视角: 1. 代数: 矩阵乘法 2. 几何: 超平面分割空间 3. 模板匹配: W 的每行是一个类模板

L.2 损失函数

交叉熵/Softmax 损失:

$$P(y = j|x) = \frac{e^{f_j}}{\sum_k e^{f_k}} \quad (\text{Softmax})$$
$$L_i = -\log P(y_i|x_i) = -f_{y_i} + \log \sum_j e^{f_j}$$

L.3 梯度下降

$$W \leftarrow W - \eta \nabla_W L$$

- η = 学习率: 太大 $\rightarrow$ 振荡/发散; 太小 $\rightarrow$ 收敛极慢
- SGD:** 每次用 mini-batch 估计梯度
- 反向传播 (Backprop): 利用链式法则高效计算梯度

L.4 反向传播链式法则

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial w}$$

- 前向: 计算各层输出
- 后向: 从损失开始, 逐层传播梯度
- 每个节点: 本地梯度 $\times$ 上游梯度

M. CNN/RNN/Attention/Transformer

M.1 卷积层 (Conv Layer)

输出尺寸公式:

$$\text{Output} = \frac{N - F + 2P}{S} + 1$$

- N = 输入尺寸, F = 滤波器大小, P = padding, S = stride

例题: Input $64 \times 64 \times 3$, kernel 3×3 , 128 filters, stride 2, padding 1
 $H_{\text{out}} = \lfloor (64 + 2 \times 1 - 3) / 2 \rfloor + 1 = \lfloor 63 / 2 \rfloor + 1 = 31 + 1 = \mathbf{32}$ Output: $32 \times 32 \times 128$

参数量: $(F \times F \times C_{\text{in}} + 1) \times C_{\text{out}} = (3 \times 3 \times 3 + 1) \times 128 = 28 \times 128 = \mathbf{3,584}$

例题: Input $32 \times 32 \times 3$, kernel 5×5 , 10 filters, stride 1, padding 0
Output = $(32 - 5 + 0) / 1 + 1 = 28 \rightarrow 28 \times 28 \times 10$ 参数量 = $(5 \times 5 \times 3 + 1) \times 10 = 76 \times 10 = \mathbf{760}$

M.2 池化层 (Pooling)

- Max Pooling: 取窗口内最大值
- Average Pooling: 取窗口内平均值
- 作用: 降低分辨率、减少参数、增加平移不变性
- 无可学习参数

M.3 RNN

$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1} + b)$$

- 同一组权重在每个时间步共享
- BPTT (Backpropagation Through Time):** 展开时间步, 反向传播
- 梯度消失/爆炸: 长序列中梯度指数衰减/增长
- LSTM:** 门控机制 (forget, input, output gate) 缓解梯度消失

M.4 Self-Attention

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

- Q (Query): “我在找什么”
- K (Key): “我包含什么信息”
- V (Value): “我的实际内容”
- 除以 $\sqrt{d_k}$: 防止点积过大导致 softmax 饱和

Multi-Head Attention: - 多个头并行做注意力 - 每个头有独立的 W_Q, W_K, W_V - 拼接所有头的输出 $\rightarrow$ 线性变换

M.5 Transformer

Encoder: [Self-Attention $\rightarrow$ Add&Norm $\rightarrow$ FFN $\rightarrow$ Add&Norm] $\times N$ **Decoder:** [Masked Self-Attention $\rightarrow$ Add&Norm $\rightarrow$ Cross-Attention $\rightarrow$ Add&Norm $\rightarrow$ FFN $\rightarrow$ Add&Norm] $\times N$

- 位置编码 (Positional Encoding): 注入位置信息 (sin/cos)
- Masked Attention:** 解码时不能看未来的 token
- Residual Connection:** 每个子层有残差连接 + Layer Norm

M.6 Vision Transformer (ViT)

- 图像 ($H \times W \times C$) $\rightarrow$ 切分为 N 个不重叠的 patch (如 16×16)
- 每个 patch 展平 $\rightarrow$ 线性投影到维度 d
- 加上位置编码 + [CLS] token
- 输入 Transformer Encoder
- [CLS] token 的输出用于分类

N. 最大似然估计与 KL 散度

N.1 KL 散度 (KL Divergence)

$$D_{KL}(p||q) = \mathbb{E}_{x \sim p} \left[\log \frac{p(x)}{q(x)} \right] = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

性质: - $D_{KL}(p||q) \geq 0$ (Gibbs 不等式) - $D_{KL}(p||q) = 0$ 当且仅当 $p = q$ - 不对称: $D_{KL}(p||q) \neq D_{KL}(q||p)$ - 解释: 用 q 编码 p 的数据时多用的额外比特数

N.2 最大似然估计 (MLE)

$$\theta^* = \arg \max_{\theta} \sum_{x \in D} \log p_{\theta}(x)$$

等价性: 最大化对数似然 $\iff$ 最小化 $D_{KL}(p_{\text{data}}||p_{\theta})$

证明: - $\min D_{KL}(p_{\text{data}}||p_{\theta}) = \min \mathbb{E}_{\text{data}} [\log p_{\text{data}}(x)] - \mathbb{E}_{\text{data}} [\log p_{\theta}(x)]$ - 第一项与 θ 无关 $\rightarrow$ 等价于 $\max \mathbb{E}_{\text{data}} [\log p_{\theta}(x)]$

N.3 蒙特卡洛估计

$$\hat{g} = \frac{1}{T} \sum_{t=1}^T g(x_t), \quad x_t \sim p$$

- 无偏: $\mathbb{E}[\hat{g}] = \mathbb{E}[g(x)]$
- 方差: $\text{Var}(\hat{g}) = \text{Var}(g(x))/T \rightarrow$ 更多样本, 更低方差

N.4 偏差-方差权衡

- 高偏差 (High Bias): 欠拟合, 模型太简单
- 高方差 (High Variance): 过拟合, 模型太复杂
- 正则化: $\text{objective} = \text{loss} + \lambda \cdot R(\theta)$, 控制复杂度

O. 潜变量模型与 VAE

O.1 潜变量模型 (Latent Variable Model)

生成过程: $z \sim p(z) \rightarrow x \sim p(x|z; \theta)$
边缘似然: $p(x; \theta) = \int p(x, z; \theta) dz = \int p(x|z; \theta) p(z) dz$
问题: 这个积分通常不可解 (intractable)

O.2 高斯混合模型 (GMM)

- $z \sim \text{Categorical}(1, \dots, K)$, 离散潜变量
- $p(x|z = k) = \mathcal{N}(\mu_k, \Sigma_k)$
- $p(x) = \sum_k \pi_k \mathcal{N}(x; \mu_k, \Sigma_k)$

O.3 ELBO(Evidence Lower Bound / 证据下界)

$$\log p(x; \theta) \geq \underbrace{\mathbb{E}_{q(z|x)}[\log p(x|z; \theta)]}_{\text{Recon}} - \underbrace{D_{KL}(q_\varphi(z|x) \| p(z))}_{\text{KL}} = \text{ELBO}$$

推导:
$$\log p(x) = \log \int p(x, z) dz = \log \int q(z|x) \cdot p(x, z)/q(z|x) dz \geq \int q(z|x) \log[p(x, z)/q(z|x)] dz \quad (\text{Jensen 不等式}) = \mathbb{E}_q[\log p(x, z)] + H(q) = \mathbb{E}_q[\log p(x|z)] - D_{KL}(q(z|x) \| p(z))$$

等号条件: $q(z|x) = p(z|x; \theta)$, 即变分分布等于真实后验
关键分解: $\log p(x) = \text{ELBO} + D_{KL}(q(z|x) \| p(z|x))$ - 因为 $D_{KL} \geq 0$, 所以 ELBO 是 $\log p(x)$ 的下界

O.4 VAE(Variational Autoencoder)

架构: - 编码器 (Encoder): $q_\varphi(z|x) = \mathcal{N}(\mu_\varphi(x), \sigma_\varphi^2(x) \cdot I) \rightarrow$ 输出 μ 和 $\log \sigma^2$
- 解码器 (Decoder): $p_\theta(x|z) \rightarrow$ 从 z 生成 x - 先验: $p(z) = \mathcal{N}(0, I)$
训练目标: 最大化 ELBO = $\mathbb{E}_q[\log p(x|z)] - D_{KL}(q(z|x) \| p(z))$

O.5 重参数化技巧 (Reparameterization Trick)

问题: $z \sim q_\varphi(z|x)$ 是随机采样, 无法反向传播
解决: - 采样 $\varepsilon \sim \mathcal{N}(0, I)$ - $z = \mu_\varphi(x) + \sigma_\varphi(x) \odot \varepsilon$ (确定性函数) - 梯度可以通过 μ 和 σ 传播!
为什么有效: 随机性转移到了 ε (与参数无关), z 是参数的确定性函数

O.6 KL 散度的解析解 (高斯情况)

当 $q = \mathcal{N}(\mu, \sigma^2 I)$, $p = \mathcal{N}(0, I)$ 时:

$$D_{KL}(q \| p) = \frac{1}{2} \sum_{j=1}^d (\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1)$$

O.7 β -VAE

- 目标: $\mathbb{E}_q[\log p(x|z)] - \beta \cdot D_{KL}(q(z|x) \| p(z))$
- $\beta > 1$: 更强的 KL 惩罚 $\rightarrow$ 更解耦的潜空间, 但重建更差/更模糊
- $\beta < 1$: 更好的重建, 但潜空间可能不够规则

O.8 VAE vs GAN: 为什么 VAE 更模糊?

- VAE 的重建项 (通常 MSE) 鼓励输出所有可能重建的平均值 $\rightarrow$ 模糊
- GAN 的对抗损失直接优化“看起来真实” $\rightarrow$ 锐利但可能不忠实

P. 标准化流模型 (Normalizing Flows)

P.1 核心思想

使 $x = f_\theta(z)$ 为确定性可逆映射, 则 $p(x)$ 可通过变量替换公式精确计算

P.2 变量替换公式 (Change of Variables)

1D:
$$p_X(x) = p_Z(h(x)) \cdot |h'(x)|, \quad h = f^{-1}$$

多维:
$$p_X(x) = p_Z(f^{-1}(x)) \cdot |\det J_{f^{-1}}(x)|$$

等价地:
$$p_X(x) = p_Z(z) \cdot |\det J_f(z)|^{-1}$$

P.3 流的组合

$$\log p_X(x) = \log p_Z(z_0) + \sum_{m=1}^M \log |\det J_{f_m^{-1}}|$$

P.4 计算效率: 三角雅可比

若 $x_i = f_i(z_{\leq i})$, 则雅可比为下三角矩阵: - $\det =$ 对角线元素之积 - $O(n)$ 计算量, 而非一般的 $O(n^3)$

P.5 NICE (加性耦合层)

- $x_{1:d} = z_{1:d}$ (直接复制)
- $x_{d+1:n} = z_{d+1:n} + m_\theta(z_{1:d})$
- $\det(J) = 1$ (体积保持)
- m_θ 可以是任意复杂的神经网络!

P.6 Real-NVP (仿射耦合层)

- $x_{1:d} = z_{1:d}$
- $x_{d+1:n} = z_{d+1:n} \odot \exp(\alpha_\theta(z_{1:d})) + \mu_\theta(z_{1:d})$
- $\det(J) = \exp(\sum \alpha) \neq 1$ (非体积保持)
- 比 NICE 表达能力更强

P.7 MAF vs IAF

	MAF	IAF
正向 $z \rightarrow x$	串行 (慢)	并行 (快)
逆向 $x \rightarrow z$	并行 (快)	串行 (慢)
适合	密度估计/训练 (MLE)	生成/采样

记忆技巧: MAF 的 M=Masked, 训练 (evaluation) 快; IAF 的 I=Inverse, 生成 (inference) 快

P.8 Parallel Wavenet

- Teacher(MAF): MLE 训练, 密度估计准确
- Student(IAF): 用 $D_{KL}(\text{student} \| \text{teacher})$ 蒸馏, 生成极快
- 结果: 采样速度提升 $\sim 1000\times$

P.9 变量替换例题

问题: $Z \sim U[0, 2]$, $X = 4Z$, 求 $p_X(x)$
解: $h(x) = x/4$, $h'(x) = 1/4$ $p_X(x) = p_Z(x/4) \cdot |1/4| = (1/2) \cdot (1/4) = \mathbf{1/8}$, $x \in [0, 8]$ 验证: $\int_0^8 (1/8) dx = 1 \checkmark$
问题: $Z \sim \mathcal{N}(0, 1)$, $X = e^Z$ (对数正态)
 $h(x) = \ln(x)$, $h'(x) = 1/x$ $p_X(x) = p_Z(\ln(x)) \cdot |1/x| = (1/\sqrt{2\pi}) \exp(-(\ln x)^2/2) \cdot (1/x)$, $x > 0$

Q. GAN(生成对抗网络)

Q.1 GAN 框架

- 生成器 **G**: $z \sim p(z) \rightarrow G(z) = x_{\text{fake}}$, 隐式定义 $p_G(x)$
- 判别器 **D**: $D(x) \rightarrow [0, 1]$, 判断 x 是否来自真实数据

Q.2 极小极大目标

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log (1 - D(G(z)))]$$

Q.3 最优判别器

固定 G, 最优 D:

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)}$$

当 $p_G = p_{\text{data}}$ 时: $D^* = 1/2$ (完全无法区分)

Q.4 最优生成器与 JSD

代入 D^* 到目标函数:

$$V(G, D^*) = 2 \cdot D_{JSD}(p_{\text{data}} \| p_G) - \log 4$$

因此最优 G 最小化 JSD 散度, 当 $p_G = p_{\text{data}}$ 时达到最小值 $-\log 4$

Q.5 Jensen-Shannon 散度

$$D_{JSD}(p, q) = \frac{1}{2} D_{KL}(p \| m) + \frac{1}{2} D_{KL}(q \| m), \quad m = \frac{p+q}{2}$$

- 对称: $JSD(p, q) = JSD(q, p)$
- 非负: $JSD \geq 0$, 等号当且仅当 $p = q$
- 有界: $0 \leq JSD \leq \log 2$

Q.6 GAN 训练算法

每次迭代: 1. 采样 m 个真实数据 $\{x_1, \dots, x_m\}$ 2. 采样 m 个噪声 $\{z_1, \dots, z_m\}$ 3. 更新 **D**(k 次梯度上升): 最大化 V 4. 更新 **G**(1 次梯度下降): 最小化 V (或最大化 $\mathbb{E}[\log D(G(z))]$)

Q.7 GAN 的问题

问题	描述
模式坍塌 (Mode Collapse)	G 只生成少数几种样本, 忽略其他模式
训练不稳定	损失振荡, D 和 G 不平衡
评估困难	样本质量 $\neq$ 似然

Q.8 似然 vs 样本质量

- 高似然 + 差样本: 模型是 p_{data} + 少量噪声 $\rightarrow$ 似然高但生成的是噪声
- 好样本 + 低似然: 模型记忆了少数训练样本 $\rightarrow$ 生成好看但无泛化
- 结论: 似然和样本质量不一定相关

Q.9 三大生成模型对比

模型	优势	劣势
GAN	样本质量高、锐利	训练不稳定、无似然、模式坍塌
VAE	训练稳定、有原则的潜空间	样本模糊
Flow	精确似然、可逆、可推断	架构受限、内存高

R. f-散度与 f-GAN 与 WGAN

R.1 f-散度 (f-Divergence)

$$D_f(p, q) = \mathbb{E}_{x \sim q} \left[f \left(\frac{p(x)}{q(x)} \right) \right]$$

f 是凸函数且 $f(1) = 0$ 。由 Jensen 不等式: $D_f(p, q) \geq f(1) = 0$
常见 **f-散度**:

散度	$f(u)$
KL	$u \log u$
逆 KL	$-\log u$
JS	$u \log u - (u + 1) \log((u + 1)/2)$
Total Variation	$\frac{1}{2} u - 1 $
χ^2	$(u - 1)^2$

R.2 f-散度的变分表示

利用 Fenchel 共轭 $f^*(t) = \sup_u \{tu - f(u)\}$:

$$D_f(p, q) \geq \sup_T \{ \mathbb{E}_{x \sim p}[T(x)] - \mathbb{E}_{x \sim q}[f^*(T(x))] \}$$

关键意义: 不需要知道密度比 p/q , 只需样本即可估计!

R.3 f-GAN

$$\min_{\theta} \max_{\varphi} \{ \mathbb{E}_{x \sim p_{data}} [T_{\varphi}(x)] - \mathbb{E}_{x \sim p_{\theta}} [f^*(T_{\varphi}(x))] \}$$

选 JS 散度 $\rightarrow$ 退化为原始 GAN

R.4 Wasserstein 距离 (EMD)

$$W(p_r, p_g) = \inf_{\gamma \in \Pi(p_r, p_g)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|]$$

- 也叫推土机距离 (Earth Mover's Distance)
- 即使分布不重叠也有意义!
- 关于参数连续可微

R.5 Kantorovich-Rubinstein 对偶

$$W(p_r, p_g) = \sup_{\|f\|_L \leq 1} \{ \mathbb{E}_{x \sim p_r}[f(x)] - \mathbb{E}_{x \sim p_g}[f(x)] \}$$

约束: f 必须是 **1-Lipschitz** 函数 ($|f(x) - f(y)| \leq |x - y|$)

R.6 WGAN 训练

- 判别器改称"critic", 输出实值分数 (不是概率)
- 目标: $\max_D \mathbb{E}_{\text{real}}[D(x)] - \mathbb{E}_{\text{fake}}[D(G(z))]$, D 需满足 1-Lipschitz

约束方法: 1. 权重裁剪 (**Weight Clipping**): $W \in [-c, c]$, 简单但优化问题多 2. 梯度惩罚 (**WGAN-GP**): 加入 $\lambda \cdot \mathbb{E}[(\|\nabla D(\hat{x})\|_2 - 1)^2]$, 更稳定

R.7 WGAN vs 原始 GAN

	原始 GAN	WGAN
散度	JSD	Wasserstein
不重叠分布	梯度为 0(无学习信号)	仍有有意义梯度
损失与质量	不相关	相关(可当训练指标)
模式坍塌	常见	几乎没有

S. BiGAN 与 CycleGAN

S.1 BiGAN(双向 GAN)

动机: 标准 GAN 只有 $G: z \rightarrow x$, 无法从 x 推断 z

架构: - 生成器 $G: z \rightarrow x$ - 编码器 $E: x \rightarrow z$ - 判别器 D : 在 (x, z) 对上操作, 区分 $(x, E(x))$ 和 $(G(z), z)$

目标:

$$\min_{G, E} \max_D \mathbb{E}_x [\log D(x, E(x))] + \mathbb{E}_z [\log(1 - D(G(z), z))]$$

结论: 均衡时 $E = G^{-1}$

S.2 CycleGAN

问题: 非配对 (unpaired) 图像域翻译

架构: - $G: X \rightarrow Y, F: Y \rightarrow X$ (两个生成器) - D_Y : 区分真 Y 和 $G(X)$, D_X : 区分真 X 和 $F(Y)$

损失: 1. 对抗损失: $L_{\text{GAN}}(G, D_Y) + L_{\text{GAN}}(F, D_X)$ 2. 循环一致性: $\lambda(\mathbb{E}[\|F(G(x)) - x\|_1] + \mathbb{E}[\|G(F(y)) - y\|_1])$

为什么需要循环一致性: - 没有它: G 可能把所有输入映射到目标域的同一种模式 (mode collapse) - 有了它: $F(G(x)) \approx x$ 保证翻译保留信息内容

S.3 AlignFlow

- 若 G 是标准化流 $\rightarrow F = G^{-1}$ 免费得到
- 精确循环一致 (exact cycle consistency)

T. 能量模型 (EBM)

T.1 EBM 定义

$$p_{\theta}(x) = \frac{\exp(f_{\theta}(x))}{Z(\theta)}, \quad Z(\theta) = \int \exp(f_{\theta}(x)) dx$$

- f_{θ} 可以是任意神经网络 (无可逆性、因式分解等限制!)
- $-f_{\theta}(x)$ 是"能量": 低能量 = 高概率
- $Z(\theta)$ = 配分函数: 通常不可解

T.2 MLE 训练的梯度

$$\nabla_{\theta} \log p_{\theta}(x_{train}) = \underbrace{\nabla_{\theta} f_{\theta}(x_{train})}_{\text{positive}} - \underbrace{\mathbb{E}_{x \sim p_{\theta}} [\nabla_{\theta} f_{\theta}(x)]}_{\text{negative}}$$

- 正相位: 推高训练数据的 f 值 (增加概率)
- 负相位: 拉低模型采样的 f 值 (降低概率)
- 负相位需要从 p_{θ} 采样 $\rightarrow$ 用 MCMC

T.3 对比散度 (Contrastive Divergence)

$$\Delta \theta \propto \nabla_{\theta} f_{\theta}(x_{train}) - \nabla_{\theta} f_{\theta}(x_{sample})$$

x_{sample} 通过 MCMC(如 Langevin dynamics) 从 p_{θ} 采样

T.4 Langevin MCMC

$$x_{t+1} = x_t + \epsilon \nabla_x f_{\theta}(x_t) + \sqrt{2\epsilon} \cdot z_t, \quad z_t \sim \mathcal{N}(0, I)$$

- 第一项 x_t : 当前位置
- 第二项 $\epsilon \nabla_x f_{\theta}$: 沿分数方向移动 (向高概率区域)
- 第三项 $\sqrt{2\epsilon} \cdot z$: 注入随机性 (探索, 避免局部陷阱)
- 当 $\epsilon \rightarrow 0, T \rightarrow \infty$ 时收敛到 p_{θ}

步长选择: - ϵ 太大: 振荡、发散、过冲 - ϵ 太小: 收敛极慢

T.5 EBM 的分数函数

$$\nabla_x \log p_{\theta}(x) = \nabla_x f_{\theta}(x) - \nabla_x \log Z(\theta) = \nabla_x f_{\theta}(x)$$

关键: $\nabla_x \log Z(\theta) = 0$ 因为 Z 不依赖于 x ! 所以 EBM 的分数函数不需要计算 Z

T.6 EBM 的可组合性

$$p_{\text{combined}}(x) \propto \prod_i p_i(x)^{\alpha_i}$$

多个 EBM 可以乘性组合 $\rightarrow$ 零样本组合推理

T.7 EBM vs 其他模型

模型	架构灵活性	采样速度	似然
Autoregressive	受限 (因式分解)	慢 (串行)	精确
Flow	受限 (可逆)	快 (并行)	精确
VAE	中等	快	下界 (ELBO)
GAN	灵活	快	不可算
EBM	最灵活	慢 (MCMC)	非归一化

U. 分数匹配与 NCE

U.1 分数函数 (Score Function)

$$s(x) = \nabla_x \log p(x)$$

- 指向数据概率增大最快的方向
- 不依赖归一化常数!

U.2 Fisher 散度

$$D_F(p||q) = \frac{1}{2} \mathbb{E}_{x \sim p} [\|s_p(x) - s_q(x)\|^2]$$

U.3 分数匹配目标 (Score Matching)

显式 (Explicit SM):

$$J(\theta) = \mathbb{E}_{x \sim p_{data}} \left[\frac{1}{2} \|s_{\theta}(x)\|^2 + \text{tr}(\nabla_x s_{\theta}(x)) \right]$$

- 需计算 Hessian 迹: $O(D^2)$, 高维不可行

U.4 去噪分数匹配 (Denoising SM, DSM)

$$J_{DSM} = \mathbb{E}_{x, \tilde{x}} \left[\left\| s_{\theta}(\tilde{x}) - \frac{x - \tilde{x}}{\sigma^2} \right\|^2 \right]$$

其中 $\tilde{x} = x + \sigma \epsilon, \epsilon \sim \mathcal{N}(0, I)$

- 目标就是预测噪声方向: $(x - \tilde{x})/\sigma^2 = -\epsilon/\sigma$
- 无需 Hessian, $O(D)$ 复杂度
- 非常简单: MSE 损失

U.5 切片分数匹配 (Sliced SM)

- 随机投影到 1D，在投影方向上做分数匹配
- $O(D)$ 复杂度，估计真实分数
- 略慢于 DSM

U.6 三种分数匹配方法对比

方法	优势	劣势
Explicit SM	估计真实分数、无需采样	Hessian $O(D^2)$ ，高维不可行
Denosing SM	高效 $O(D)$ ，简单 MSE	只估计噪声扰动后的分数
Sliced SM	$O(D)$ ，估计真实分数	略慢于 DSM

U.7 NCE(噪声对比估计)

思想: 将密度估计转化为二分类 (数据 vs 噪声)
判别器:

$$D_{\theta,Z}(x) = \frac{e^{f_{\theta}(x)/Z}}{e^{f_{\theta}(x)/Z} + p_n(x)}$$

损失: 标准交叉熵 (binary cross-entropy)

特点: - Z 作为可学习参数 - 噪声分布 p_n 需覆盖数据支撑集 - 与 GAN 对比: NCE 显式学习密度比, GAN 用独立生成网络

V. 扩散模型 (Diffusion Models)

V.1 NCSN (Noise Conditional Score Network)

动机: 单一噪声水平无法同时保证准确分数估计和好的数据质量

方法: 使用多噪声水平 $\sigma_1 > \sigma_2 > \dots > \sigma_L$

训练 $s_{\theta}(x, \sigma)$ 在所有噪声水平上:

$$\sum_{i=1}^L \lambda(\sigma_i) \mathbb{E}_{x, \tilde{x}} \left[\left\| s_{\theta}(\tilde{x}, \sigma_i) - \frac{x - \tilde{x}}{\sigma_i^2} \right\|^2 \right]$$

退火朗之万动力学 (Annealed Langevin): 1. 从最大噪声 σ_1 开始 $\rightarrow$ 粗略定位模式 2. 逐步降低到 $\sigma_2, \sigma_3, \dots$ 3. 每级的采样结果作为下级初始化 4. 最终在最小噪声 σ_L 产生高质量样本

直觉: 粗到细 (coarse-to-fine) — 大噪声全局探索, 小噪声局部细化

V.2 DDPM (Denoising Diffusion Probabilistic Model)

前向过程 (Forward Process, 固定)

$$q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$, $\beta_t \in [10^{-4}, 0.02]$ (线性 schedule)

等价地: $x_t = \sqrt{\bar{\alpha}_t} \cdot x_0 + \sqrt{1 - \bar{\alpha}_t} \cdot \varepsilon$, $\varepsilon \sim \mathcal{N}(0, I)$

当 $T \approx 1000$ 时: $x_T \approx \mathcal{N}(0, I)$ (纯噪声)

逆向过程 (Reverse Process, 可学习)

$$p_{\theta}(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t, t), \sigma_t^2 I)$$

训练损失 (简化)

$$L = \mathbb{E}_{t, x_0, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(x_t, t)\|^2 \right]$$

- ϵ : 前向过程中实际加入的噪声 (ground truth)
- ϵ_{θ} : 网络预测的噪声
- $t \sim U\{1, \dots, T\}$
- 等价于加权 ELBO

为什么预测噪声而非 x_0 ?

1. ϵ 总是 $\sim \mathcal{N}(0, I)$, 不随 t 变化 $\rightarrow$ 一致的学习目标
2. 预测 x_0 需处理不同 t 下差异极大的目标分布
3. 通过 Tweedie 公式: 噪声预测等价于分数函数估计

采样过程 (Generation)

从 $x_T \sim \mathcal{N}(0, I)$ 开始, for $t = T, T - 1, \dots, 1$:

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_{\theta}(x_t, t) \right) + \sigma_t z$$

$z \sim \mathcal{N}(0, I)$ (当 $t > 1$ 时), $z = 0$ (当 $t = 1$ 时)

直觉: 预测噪声 $\rightarrow$ 减去噪声 $\rightarrow$ 加少量随机性 $\rightarrow$ 得到稍清晰的 x_{t-1}

分数函数关系

$$\nabla_{x_t} \log p(x_t) = -\frac{\epsilon_{\theta}(x_t, t)}{\sqrt{1 - \alpha_t}}$$

所以 DDPM 训练本质是多尺度去噪分数匹配!

V.3 DDPM 作为层次化 VAE

- 编码器 = 固定的前向过程 (加噪)
- 解码器 = 可学习的逆向过程 (去噪)
- ELBO 退化为去噪分数匹配损失

V.4 SDE 框架 (连续时间)

前向 SDE

$$dx = f(x, t)dt + g(t)dw$$

逆时 SDE

$$dx = [f(x, t) - g(t)^2 \nabla_x \log p_t(x)]dt + g(t)d\bar{w}$$

概率流 ODE

$$dx = \left[f(x, t) - \frac{1}{2}g(t)^2 \nabla_x \log p_t(x) \right] dt$$

V.5 SDE vs ODE 采样

	逆时 SDE	概率流 ODE
随机性	有 (每步加噪)	确定性
多样性	高	低 (同噪声 $\rightarrow$ 同输出)
似然计算	不可精确	可精确 (连续 normalizing flow)
求解器	Euler-Maruyama	自适应步长 ODE solver(更快)
边际分布	$p_t(x)$	相同 $p_t(x)$

V.6 预测-校正采样 (Predictor-Corrector)

1. **Predictor**: 数值 SDE/ODE 求解一步
2. **Corrector**: Langevin MCMC 步校正

V.7 Classifier-Free Guidance

训练: 随机丢弃条件 c (概率 p_{uncond}), 同一网络同时学: - 条件生成: $\epsilon_{\theta}(x_t, t, c)$ - 无条件生成: $\epsilon_{\theta}(x_t, t, \emptyset)$

采样:

$$\tilde{\epsilon} = \epsilon_{\theta}(x_t, t, \emptyset) + w \cdot [\epsilon_{\theta}(x_t, t, c) - \epsilon_{\theta}(x_t, t, \emptyset)]$$

- $w > 1$: 放大条件信号 $\rightarrow$ 质量更高但多样性降低
- $w = 1$: 标准条件生成
- $w = 0$: 无条件生成

V.8 Latent Diffusion (Stable Diffusion)

- 在低维潜空间做扩散 (而非像素空间)
- 优势: 更快、更省内存、可用预训练 VAE 编码器
- 可应用于非图像数据

V.9 U-Net 架构

- 编码器-解码器 + 跳跃连接 (skip connections)
- 时间 t 通过位置编码注入
- 中间分辨率处使用 attention

W. Practice Session 例题精解

Q1. CNN & Transformer

(a) Input $64 \times 64 \times 3$, kernel 3×3 , 128 filters, stride 2, padding 1

$H_{\text{out}} = \lfloor (64 + 2 \times 1 - 3)/2 \rfloor + 1 = \lfloor 63/2 \rfloor + 1 = 31 + 1 = \mathbf{32} \rightarrow \text{Output: } 32 \times 32 \times 128$

Parameters $= (3 \times 3 \times 3 + 1) \times 128 = 28 \times 128 = \mathbf{3,584}$

(b) ViT: (i) 图像切成 N 个 patch (如 16×16) $\rightarrow$ 展平 $\rightarrow$ 线性投影到 d 维 $\rightarrow$ 加位置编码 $\rightarrow N$ 个 token (ii) Q=“我在找什么”, K=“我有什么”, V=“实际内容”; $\alpha_{ij} = \text{softmax}(Q_i K_j^T / \sqrt{d_k})$

Q2. VAE

(a) ELBO $= \mathbb{E}_{q(z|x)}[\log p(x|z)] - D_{\text{KL}}(q_{\varphi}(z|x) \| p(z))$ - 第一项: 重建损失 - 第二项: KL 散度 (后验 vs 先验)

(b) 重参数化: $z = \mu_{\varphi}(x) + \sigma_{\varphi}(x) \odot \varepsilon$, $\varepsilon \sim \mathcal{N}(0, I) \rightarrow z$ 是 μ, σ 的确定性函数, 梯度可通过 μ 和 σ 反传

(c) $D_{\text{KL}}(\mathcal{N}(\mu, \sigma^2) \| \mathcal{N}(0, 1)) = \frac{1}{2}(\mu^2 + \sigma^2 - \log \sigma^2 - 1)$

$\beta > 1$: 更强 KL 惩罚 $\rightarrow$ 更解耦但重建差 VAE 模糊: 重建项 (MSE) 输出多种可能重建的平均 $\rightarrow$ 模糊; GAN 直接优化”看起来真实”

Q3. GAN

(a) $\min_G \max_D \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))]$ $D^*(x) = p_{\text{data}} / (p_{\text{data}} + p_G)$
代入: $C(G) = -\log 4 + 2 \cdot D_{\text{JSD}}(p_{\text{data}} \| p_G)$

(b) 模式坍塌: G 只产生少数类型样本 (如只生成猫不生成狗) WGAN-GP: 用 Wasserstein 距离 (即使不重叠也有梯度) + 梯度惩罚强制 Lipschitz

(c) 见上方”三大生成模型对比”表

Q4. Diffusion

(a) ε = 实际加入的噪声 (GT); ε_{θ} = 网络预测噪声 预测噪声好因为: ε 总是 $\sim \mathcal{N}(0, I)$ 不随 t 变; 分数关系: $\nabla \log p_t = -\varepsilon_{\theta} / \sqrt{1 - \alpha_t}$

(b) $x_{t-1} = (1/\sqrt{\alpha_t})(x_t - (1 - \alpha_t)/\sqrt{1 - \alpha_t} \cdot \varepsilon_{\theta}(x_t, t)) + \sigma_t \cdot z$

(c) Classifier-free guidance: 训练时随机 drop 条件; 推断时 $\tilde{\epsilon} = \varepsilon_{\text{uncond}} + w \cdot (\varepsilon_{\text{cond}} - \varepsilon_{\text{uncond}})$ Latent diffusion: 低维潜空间 $\rightarrow$ 更快更省内存

Q5. EBM & Score Matching

(a) $Z(\theta) = \int \exp(f_{\theta}(x)) dx$ 高维积分不可解证明: $\nabla_x \log p_{\theta} = \nabla_x f_{\theta} - \nabla_x \log Z = \nabla_x f_{\theta}$ (因 Z 不依赖 x)

(b) 见上方”三种分数匹配方法对比”表

(c) Langevin 三项: x_t (当前), $\varepsilon \cdot s_{\theta}$ (沿分数方向/高概率), $\sqrt{2\varepsilon} \cdot z$ (随机性/探索) η 太大 $\rightarrow$ 振荡发散; η 太小 $\rightarrow$ 收敛极慢

(d) NCSN: 大 σ 填低密度区 $\rightarrow$ 跨模式移动; 小 σ 保细节退火朗之万: σ_1 开始粗定位 $\rightarrow$ 逐步降到 $\sigma_L \rightarrow$ 精细化

附录: 快速公式索引

公式名	公式	页面
卷积	$G[i, j] = \sum \sum H[m, n] \cdot F[i - m, j - n]$	A
高斯合并	$\sigma_{\text{eff}} = \sqrt{\sigma_1^2 + \sigma_2^2}$	A
Harris 响应	$R = \lambda_1 \lambda_2 - \alpha (\lambda_1 + \lambda_2)^2$	D
Conv 输出	$(N - F + 2P)/S + 1$	M
透视投影	$u = fX/Z + cx, \ v = fY/Z + cy$	J
立体深度	$Z = fB/d$	K
RANSAC 轮数	$N = \log(1 - p) / \log(1 - (1 - e)^S)$	I
ELBO	$\mathbb{E}_q[\log p(x z)] - D_{\text{KL}}(q\ p(z))$	O
变量替换	$p_X = p_Z(f^{-1}(x)) \cdot \det J_{f^{-1}} $	P
GAN 目标	$\min_G \max_D \mathbb{E}[\log D] + \mathbb{E}[\log(1 - D(G))]$	Q
最优判别器	$D^* = p_{\text{data}} / (p_{\text{data}} + p_G)$	Q
Wasserstein	$\sup_{\ f\ _L \leq 1} \mathbb{E}_r[f] - \mathbb{E}_g[f]$	R
EBM	$p_\theta = \exp(f_\theta)/Z$	T
EBM 梯度	$\nabla f_\theta(x_{\text{train}}) - \mathbb{E}_{p_\theta}[\nabla f_\theta(x)]$	T
Langevin	$x_{t+1} = x_t + \varepsilon \nabla f + \sqrt{2\varepsilon} z$	T
DSM	$\mathbb{E}[\ s_\theta(\tilde{x}) - (x - \tilde{x})/\sigma^2\ ^2]$	U
DDPM 前向	$q(x_t x_0) = \mathcal{N}(\sqrt{\alpha_t} x_0, (1 - \alpha_t)I)$	V
DDPM 损失	$\mathbb{E}[\ \varepsilon - \varepsilon_\theta(x_t, t)\ ^2]$	V
逆时 SDE	$dx = [f - g^2 \nabla \log p_t] dt + g d\bar{w}$	V
概率流 ODE	$dx = [f - \frac{1}{2} g^2 \nabla \log p_t] dt$	V
CFG	$\bar{\varepsilon} = \varepsilon_{\text{uncond}} + w \cdot (\varepsilon_{\text{cond}} - \varepsilon_{\text{uncond}})$	V